

# AI 에이전트

## 전문가 양성 과정

PJT\_01



# PubMed API 활용 데이터 수집

# 개요

# 개요

- 프로젝트 개요
  - NCBI는 미국 국립보건원 (NIH) 산하의 생명과학·의생명 데이터 포털로, 논문, 임상 연구 등 바이오·의료 연구에 필요한 공개 데이터를 검색하고 활용할 수 있게 제공하는 기관입니다.
  - NCBI PubMed API를 사용해 의료·바이오 논문 데이터를 직접 수집하고 정리하시오.
- 프로젝트 목표
  - NCBI PubMed API Key를 발급받고 안전하게 사용하는 방법을 익힌다.
  - `requests.get()`과 URL 파라미터를 사용해 API 데이터를 요청한다.
  - JSON, XML, CSV 파일을 읽고 저장한다.
  - 반복문, 조건문, 리스트, 딕셔너리로 논문 데이터를 집계한다.

# 준비사항

# 준비사항

- NCBI 계정 생성 및 API Key 발급
  - NCBI API 가이드 : <https://www.ncbi.nlm.nih.gov/home/develop/api/>
  - NCBI가 제공하는 여러 데이터베이스 중 PubMed만 조회 대상으로 사용하시오
  - NCBI 제공 데이터 베이스

| 데이터베이스 구분          | 제공 정보                                 |
|--------------------|---------------------------------------|
| PubMed             | 논문 제목, 초록, 저자, 저널, PMID 등 논문 메타데이터 중심 |
| PMC                | 무료로 공개된 논문 전문, full-text 중심           |
| Gene               | 유전자 정보                                |
| Protein            | 단백질 정보                                |
| Nucleotide/Nuccore | DNA/RNA 염기서열 정보                       |

# 요 구 사 항


# 요구사항

- AI를 사용하지 않고, 스스로 해결하시오.
- 제출 기한 : 오늘 18시
- 최종 레포지토리 구성
  - problem\_01.py : 1번 요구사항 정답 코드
  - problem\_02.py : 2번 요구사항 정답 코드
  - ...
  - output/ : 각 코드를 실행한 결과물
  - README.md : 각 요구 사항을 어떻게 구현했는지 상세히 기록
  - .gitignore : API Key 등 중요한 데이터를 업로드하지 않도록 설정




# 요구사항

- Collaborators에 강사를 추가하시오. (1/2)
- 레포지토리 - Settings - Collaborators - Add people



# 요구사항

- Collaborators에 강사를 추가하시오. (2/2)
  - id : gangnamAGENT



# 요구사항

- 요구사항은 1번부터 8번까지 있습니다.
- 1번부터 5번까지는 필수 과제, 6번부터 8번은 도전 과제입니다.
- 도전 과제는 필수로 구현해야 하는 과제는 아니지만, 필수 과제를 모두 수행한 교육생은 도전 하시오.

# 요구사항

- 요구사항 1 - API Key 발급 및 기본 검색
  - `ESearch`로 `artificial intelligence cancer`를 검색한 응답을 outputs 폴더에 `raw\_esearch\_ai\_cancer.json`으로 저장하시오
  - 이때 전체 검색 결과 수 `count`와 가져온 idList 5개를 터미널에 출력하시오.
  - 터미널 출력 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

전체 검색 결과 수: 68583

가져온 PMID 5개: 42418827, 42418754, 42418739, 42418670, 42418410

# 요구사항

- 요구사항 1 - API Key 발급 및 기본 검색
  - raw\_esearch\_ai\_cancer.json 예시(응답 결과는 실행 시점에 따라 다를 수 있음)

```
{
  "header": {
    "type": "esearch",
    "version": "0.3"
  },
  "esearchresult": {
    "count": "68583",
    "retmax": "5",
    "retstart": "0",
    "idlist": [
      "42418827",
      "42418754",
      "42418739",
      "42418670",
      "42418410"
    ],
    "translationset": [
      {
        "from": "artificial intelligence",
        "to": "\"artificial intelligence\"[MeSH Terms] OR (\"artificial\"[All Fields] AND \"intelligence\"[All Fields]) OR \"a"
      }
    ]
  }
}
```

# 요구사항

- 요구사항 2 - 여러 주제어 검색 결과 비교
  - 아래 5개 Topics를 각각 `ESearch`로 검색하고, 주제별 논문 수를 outputs 폴더에 `topic\_counts.csv`로 저장하고, 검색 결과가 가장 많은/적은 주제어를 출력하는 코드를 구현하시오.
- Topics
  - machine learning diabetes
  - deep learning radiology
  - Alzheimer biomarker
  - COVID-19 vaccine
  - cancer immunotherapy

# 요구사항

- 요구사항 2 - 여러 주제어 검색 결과 비교
  - 터미널 출력 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

```
검색 결과가 가장 많은 주제어: cancer immunotherapy 231842개  
검색 결과가 가장 적은 주제어: machine learning diabetes 8190개
```

# 요구사항

- 요구사항 2 - 여러 주제어 검색 결과 비교
  - topic\_counts.csv 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

```
topic,count
machine learning diabetes,8190
deep learning radiology,23389
Alzheimer biomarker,35185
COVID-19 vaccine,60636
cancer immunotherapy,231842
```



# 요구사항

- 요구사항 3 - 특정 주제 논문 50개 수집
  - `cancer immunotherapy`를 검색해 PMID 50개를 수집하고, 그 수집한 PMID 목록을 `outputs/pmids\_cancer\_immunotherapy.txt`로 저장하고 첫 번째 PMID와 마지막 PMID를 터미널에 출력하시오.
  - 터미널 출력 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

```
저장된 PMID 수: 50  
첫 번째 PMID: 42379203  
마지막 PMID: 41792971
```

# 요구사항

- 요구사항 3 - 특정 주제 논문 50개 수집
  - pmids\_cancer\_immunotherapy.txt 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

|    |          |
|----|----------|
| 1  | 42379203 |
| 2  | 42402813 |
| 3  | 42396795 |
| 4  | 42393838 |
| 5  | 42381384 |
| 6  | 42345602 |
| 7  | 42345355 |
| 8  | 42343214 |
| 9  | 42335104 |
| 10 | 42322272 |

# 요구사항

- 요구사항 4 - 연도별 논문 수 분석
  - `CRISPR gene therapy`라는 용어가 2021년, 2022년, 2023년, 2024년, 2025년의 검색 결과 몇 번 등장하는지 수를 구하는 코드를 구현하고, 이때 검색 결과가 가장 많은 연도는 언제이며 몇 편인지 출력하시오. (datatype : pdat)
  - 터미널 출력 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

```
검색 결과가 가장 많은 연도: 202[]년  
논문 수: 18..개
```

# 요구사항

- 요구사항 5 - 저널별 빈도 분석
  - data 폴더 속 `summary\_cancer\_immunotherapy.csv`를 읽어 저널별 논문 수를 계산하는 코드를 작성해 가장 많이 등장한 저널명과 논문 수를 출력하시오.
  - 터미널 출력 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

```
가장 많이 등장한 저널명: 0n....  
논문 수: 2..개
```

# 도전 과제

# 요구사항

- 요구사항 6 – Abstract 데이터 수집
  - 3번에서 구현한 `pmids_cancer_immunotherapy.txt` 속 PMID 50개를 ``EFetch``를 활용해 Abstract 속 `AbstractText`를 추출하시오. 추출한 결과를 ``outputs/abstracts_cancer_immunotherapy.csv``에 저장하시오
  - ``abstracts_cancer_immunotherapy.csv`` 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

| pmid     | title                                                                                                                                                         | abstract                                                                                                                                                                                                            |
|----------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 42379203 | Severe anaemia and invasive bacterial infections in Kenyan children: a 26-year hospital surveillance observational study.                                     | Severe anaemia is a major cause of hospital admission and mortality in children living in sub-Saharan Africa, but data on its association with invasive bacterial infection are sparse. We aimed to characterise    |
| 42402813 | Preclinical proof of concept for a personalized SNAP™-TIL (Specific Neo-Antigen Peptides-TIL) therapy platform.                                               | Tumor-infiltrating lymphocyte (TIL) therapy, which involves extracting, expanding, and reinfusing immune cells to target cancer cells, has shown promise in melanoma treatment, but requires optimization for       |
| 42396795 | Perceptions, knowledge, and access to the HPV vaccine among parents and healthcare providers in South Quito, Ecuador in 2025: A qualitative study.            | Human papillomavirus (HPV) is estimated to cause 99.7% of all cervical cancers and is the main cause of anal cancer. Despite global progress, Ecuador has one of the highest cervical cancer mortality rates        |
| 42393838 | Intratumoral enrichment and suppressive activity of DP8α regulatory T cells in human colorectal cancer.                                                       | Colorectal cancer (CRC) progression is driven by dynamic interactions among tumor cells, immune infiltrates, and the gut microbiota. While regulatory T cells (Tregs) may contribute to immune suppression in       |
| 42381384 | Ex vivo-generated conventional dendritic cells type 1 and type 2 from blood progenitors induce potent antigen-specific T-cell immunity.                       | While existing cancer therapies manage to reduce tumor burden, they often fail to produce durable or curative outcomes. Alternatively, cell-based approaches - particularly dendritic cell (DC) vaccines conce      |
| 42345602 | Early neutrophil infiltration promotes TRIMELVax-induced antitumor immunity by linking local inflammation to tumor control.                                   | Enhancing innate-adaptive immune crosstalk is key for improving cancer vaccine efficacy. TRIMELVax is a heat shock-conditioned whole-tumor-cell vaccine combining xenogeneic melanoma cell lysate, syn              |
| 42345355 | Advances in SEC61G research: from ER translocon subunit to emerging pan-cancer oncogenic roles.                                                               | SEC61G, the γ subunit of the Sec61 translocon, has long been regarded as a passenger co-amplification target of EGFR on chromosome 7p11.2. Recent studies have revealed its independent oncogenic fu                |
| 42343214 | Sequential axitinib and survivin vaccination unlock curative PD-1 immunotherapy in renal carcinoma.                                                           | Despite significant progress achieved by combining VEGFR tyrosine-kinase inhibitors (TKIs) with immune checkpoint inhibitors (ICIs), complete responses remain rare in metastatic renal cell carcinoma (mRC         |
| 42335104 | The dual role of leukotrienes in the tumor microenvironment: balancing pro-tumorigenic and anti-tumor immunity.                                               | Leukotrienes are bioactive lipid mediators produced via the 5-lipoxygenase (5-LO) pathway and are essential for inflammatory signaling in the tumor microenvironment (TME), playing roles in angiogenesis, in       |
| 42322272 | Pooled analysis of 2 clinical trials of first-line chemioimmunotherapy for metastatic microsatellite stable colorectal cancer MEDITREME and METIMMOX studies. | Colorectal cancer with microsatellite stable (MSS) status is intrinsically resistant to immune checkpoint inhibitor monotherapy targeting PD-1 or PD-L1. However, emerging evidence suggests that chemother         |
| 42318705 | Osonization and timing as key determinants of MBTA immunotherapy efficacy in pancreatic adenocarcinoma and recurrence treatment.                              | Pancreatic adenocarcinoma is a highly aggressive cancer with very limited treatment options. This study aimed to optimize the efficacy of a previously developed tumor immunotherapy for the treatment of t         |
| 42298353 | Gut microbial markers of immunotherapy response in melanoma: a cross-cohort analysis including the first Russian dataset.                                     | Melanoma is an aggressive malignancy with a significant risk of mortality. In recent years, treatment strategies have undergone a paradigm shift with the advent of immunotherapy, particularly immune check        |
| 42275298 | Significance of GSH and H2S regulation for cancer: an intricate interplay between diet, microbiota, metabolic reprogramming, and immune health.               | Due to the proliferative nature of cancer cells, they utilize more dietary extracellular nutrients via one-carbon metabolism for the various metabolic processes, including the synthesis of antioxidants such as g |

# 도전 과제

- 요구사항 7 - 키워드 포함 여부 분석
  - 아래 분석 키워드 중 6번에서 구현한 `abstracts_cancer_immunotherapy.csv` 속 `title`과 `abstract`에서 가장 자주 등장하는 키워드와, 해당 키워드가 포함된 논문의 수를 출력하시오
- 분석 키워드
  - `immunotherapy`
  - `tumor`
  - `survival`
  - `response`
  - `clinical trial`

# 도전 과제

- 요구사항 7 - 키워드 포함 여부 분석
  - 터미널 출력 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

```
가장 많이 등장한 키워드: survival (예시)  
등장 논문 수: 4..개
```



# 도전 과제

- 요구사항 8 - 최종 비교 리포트 작성
  - 다음 3개 Topics를 각각 `ESearch`로 검색하고 각 Topic별 최신 논문 20개의 PMID, 제목, 저널, 출판일을 `outputs/final\_topic\_comparison.csv`로 저장하고, 아래 질문에 대한 답변을 터미널에 출력하시오
- Topics
  - precision medicine oncology
  - wearable device hypertension
  - microbiome obesity
- 질문
  - 세 주제 중 검색 결과 수가 가장 많은 주제는?
  - 최신 논문 20개 중 제목에 `patient`가 포함된 논문은 주제별로 몇 편인가요?

# 도전 과제

- 요구사항 8 - 최종 비교 리포트 작성
  - 터미널 출력 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

```
세 주제 중 검색 결과 수가 가장 많은 주제: precision medicine oncology 62086
patient 포함 논문 수: {'precision medicine oncology': 1, 'wearable device
hypertension': 1, 'microbiome obesity': 0}
가장 최근 연도 논문의 PMID: 42402813
가장 최근 연도 논문의 제목: Preclinical proof of concept for a personalized
SNAP™-TIL (Specific Neo-Antigen Peptides-TIL) therapy platform.
```

# 도전 과제

- 요구사항 8 - 최종 비교 리포트 작성
  - final\_topic\_comparison.csv 예시 (응답 결과는 실행 시점에 따라 다를 수 있음)

| topic                       | total_count | pmid     | title                                                                                                                                                | source                                         | pubdate     |
|-----------------------------|-------------|----------|------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------|-------------|
| precision medicine oncology | 62086       | 42402813 | Preclinical proof of concept for a personalized SNAP™-TIL (Specific Neo-Antigen Peptides-TIL) therapy platform.                                      | Oncoimmunology                                 | 2026 Dec 31 |
| precision medicine oncology | 62086       | 42377119 | NSUN2 mediates SALL2 m5C methylation to inhibit ferroptosis and promote breast cancer progression.                                                   | Cancer Biol Ther                               | 2026 Dec 31 |
| precision medicine oncology | 62086       | 42335104 | The dual role of leukotrienes in the tumor microenvironment: balancing pro-tumorigenic and anti-tumor immunity.                                      | Cancer Biol Ther                               | 2026 Dec 31 |
| precision medicine oncology | 62086       | 42240026 | RET fusion partners dictate oncogenic potential in undifferentiated spindle cell sarcomas.                                                           | Cancer Biol Ther                               | 2026 Dec 31 |
| precision medicine oncology | 62086       | 42212684 | Decoding the microbiome: artificial intelligence-targeted gut microenvironment breakthroughs in personalized cancer therapy.                         | Gut Microbes                                   | 2026 Dec 31 |
| precision medicine oncology | 62086       | 42092750 | Targeted proteoform degradation for precision drug design, delivery, and therapy.                                                                    | Drug Deliv                                     | 2026 Dec 31 |
| precision medicine oncology | 62086       | 42015346 | Gut microbiome and metabolic health: mechanisms and precision interventions.                                                                         | Gut Microbes                                   | 2026 Dec 31 |
| precision medicine oncology | 62086       | 41992448 | Angiopep-2-decorated bacterial outer membrane vesicles penetrate the blood-brain barrier for glioblastoma chemo-immunotherapy.                       | Drug Deliv                                     | 2026 Dec 31 |
| precision medicine oncology | 62086       | 41866709 | Extracellular payload release from non-internalizing antibody-drug conjugates: mechanisms and linker technologies.                                   | Drug Deliv                                     | 2026 Dec 31 |
| precision medicine oncology | 62086       | 41582518 | In vitro generated macrophages reflect the immunosuppressive phenotype of in vivo glioblastoma-associated macrophages.                               | Oncoimmunology                                 | 2026 Dec 31 |
| precision medicine oncology | 62086       | 41459935 | A dual diacylglycerol kinase (DGK) alpha/zeta inhibitor augments the activity of human tumor infiltrating lymphocytes in in vivo and ex vivo models. | Oncoimmunology                                 | 2026 Dec 31 |
| precision medicine oncology | 62086       | 41723613 | [THE PRECISION APPROACH IN CONTEMPORARY NEUROSURGICAL PRACTICE: A REVIEW].                                                                           | Probl Sotsialnoi Gig Zdravookhrannii Istor Med | 2026 Dec 15 |
| precision medicine oncology | 62086       | 42375141 | Recent advances in HER2-targeted inhibitors for cancer therapy.                                                                                      | Pharm Sci Adv                                  | 2026 Dec    |
| precision medicine oncology | 62086       | 42360103 | Inflammation and carcinogenesis: molecular targets and small-molecule intervention strategies.                                                       | J Enzyme Inhib Med Chem                        | 2026 Dec    |
| precision medicine oncology | 62086       | 42318797 | Research progress of ferroptosis in gynecological diseases.                                                                                          | Ann Med                                        | 2026 Dec    |

수고하셨습니다.

